


VLA 기반 소형 로봇팔 항만 **비정형** 화물 자동 분류 시스템

2026. 4. 10

국립목포해양대학교
김 동 관

VLA란 무엇인가?




Vision-Language-Action Model

카메라 영상(Vision)과 자연어 명령(Language)을 입력받아
로봇 관절 제어값(Action)을 출력하는 통합 AI 모델

핵심 특징

- 대규모 언어 모델(LLM) 기반 로봇 제어
- 사전 프로그래밍 없이 새로운 작업 수행
- 대표 모델: Google RT-2, Octo, **SmolVLA**



SmolVLA 소개

HuggingFace 리로봇(LeRobot) 팀이 개발한 컴팩트 VLA 모델
— 본 프로젝트의 핵심 AI 엔진


모델 핵심 스펙

- 파라미터: 450M (경량)
- 라이선스: Apache 2.0 (오픈소스)
- 소비자 GPU/CPU에서 추론 가능
- 비동기 추론: 30% 빠른 응답, 2배 처리량
- 학습 환경: 단일 GPU(A100)에서 ~4시간

프로젝트 연계 가치

- 450M 경량 모델 → 엣지 배포 용이
- LeRobot 프레임워크와 완전 통합
- RTX 4090에서 파인튜닝 → 비용 절감
- 커뮤니티 데이터셋으로 사전학습 완료
- 항만 환경 파인튜닝으로 즉시 적용 가능

핵심 기술: VLA 모델



영상 + 자연어 명령 → 관절 제어값 출력하는 통합 AI 모델

VLA 모델 소개

Vision-Language-Action Model의 핵심 개념과 발전 과정

핵심 개념

- 카메라 영상 + 자연어 명령 → 로봇 행동 출력
- VLM 기반 장면 이해 & 언어 추론
- Action Decoder로 연속 제어 신호 생성

아키텍처 패턴

- 단일 모델: RT-2, OpenVLA, $\pi 0$
- 이중 시스템: Helix, Groot N1 (고속 제어)
- Action 방식: 토큰 이산화 vs Flow/Diffusion

주요 모델 타임라인

- 2023 Google RT-2 (VLA 패러다임 제시)
- 2024 OpenVLA 7B (오픈소스 공개)
- 2025 SmolVLA 450M (소형화 & 민주화)

왜 중요한가?

- 사전 프로그래밍 없이 새 작업 일반화
- 자연어로 로봇에 직접 지시 가능
- 소형 모델로도 실시간 제어 실현

VLA 모델 비교

모델	파라미터	Vision Encoder	Language Model	Action 방식	학습 데이터
RT-2	55B	ViT (PaLI-X)	PaLM-E	Token (이산화)	Google 내부 데이터
OpenVLA	7B	SigLIP + DINOv2	Llama-2 7B	Token (이산화)	Open X-Embodiment
$\pi 0$	3.3B	SigLIP (PaliGemma)	Gemma-2 2B	Flow Matching	자체 수집 + OXE
Helix	7B+80M	Open VLM	System 2 VLM	Continuous (S1)	자체 ~500시간
SmolVLA	450M	SigLIP	SmolLM2	Flow Matching	LeRobot 커뮤니티

💡 핵심 포인트

SmolVLA는 450M 파라미터로 수십억 규모 모델과 경쟁하며, 소비자급 GPU에서 실행 가능한 유일한 오픈소스 VLA 모델임

Action Decoding 전략

VLA 모델의 두 가지 주요 액션 출력 방식

Token-based (이산화)

- 연속 액션을 이산 토큰으로 변환
- LLM과 동일한 next-token prediction
- 보통 255개 bins로 액션 공간 양자화
- 학습 간단, 정밀도 제한적

대표 모델: RT-2, OpenVLA

Flow Matching (연속)

- 연속 액션 궤적을 직접 출력
- 노이즈 → 액션 변환 (denoising process)
- 높은 정밀도, 50Hz 제어 가능
- 부드러운 모터 제어에 최적

대표 모델: $\pi 0$, **SmolVLA**

SmolVLA 개요

Hugging Face LeRobot | 450M Parameters | Apache 2.0 License

아키텍처 구성

- VLM: SmolVLM-2 (SigLIP + SmolLM2)
- Action Expert: Flow Matching 기반 디코더
- Cross-Attention + Self-Attention 인터리빙

최적화 전략

- Layer Skipping: VLM 상위 레이어 절반 생략
- PixelShuffle: 이미지당 64 토큰으로 압축
- 비동기 추론: 30% 빠른 응답, 2배 처리량

학습 & 데이터

- LeRobot 커뮤니티 데이터셋 (487개, 오픈소스)
- 파인튜닝: A100 1대로 ~4시간 (20K steps)
- ~50 에피소드 데모로 태스크 학습 가능

실행 환경

- 추론: 일반 GPU 또는 CPU에서도 가능!
- 저가형 로봇: SO100, SO101 호환
- LIBERO, Meta-World 시뮬레이션 벤치마크지원

SmolVLA 아키텍처 상세

VLM Backbone

SmolVLM-2

- SigLIP vision encoder로 이미지 인코딩
- PixelShuffle로 64 토큰/프레임 압축
- SmolLM2 language decoder
- 텍스트 명령어를 토큰화하여 입력
- Layer Skipping: 중간 레이어 (L/2)에서 특성 추출

Action Expert

Flow Matching Transformer

- VLM 특성을 Cross-Attention으로 수신
- Causal Self-Attention으로 시퀀스 일관성
- CA + SA 인터리빙 구조
- 노이즈 → 연속 액션 궤적 생성
- Action Chunk 단위 출력 (다중 스텝)

입력 & 출력

멀티모달 → 로봇 명령

- 입력: 다시점 RGB 카메라 이미지
- 입력: 자연어 태스크 지시문
- 입력: 로봇 센서모터 상태 (proprio)
- 출력: 연속 관절/그리퍼 명령
- 비동기 추론으로 실시간 제어

핵심 최적화 기법

01 Layer Skipping

VLM의 상위 레이어를 건너뛰고 중간 레이어(L/2)에서 특성을 추출합니다. 전체 레이어를 통과하지 않아도 액션 생성에 충분한 특성을 확보하면서, 추론 속도를 크게 향상시킵니다.

02 PixelShuffle Token Compression

512×512 이미지를 1024개 대신 64개 비주얼 토큰으로 압축합니다. 글로벌 이미지만 사용하고 타일링을 제거하여 메모리와 연산량을 대폭 절감합니다.

03 비동기 추론 (Async Inference)

현재 액션 실행 중 다음 액션을 미리 계산합니다. 액션 간 대기 시간을 제거하여 30% 빠른 응답과 2배의 태스크 처리량을 달성합니다.

04 CA+SA 인터리빙

Action Expert에서 Cross-Attention과 Causal Self-Attention을 교대로 배치합니다. VLM 특성 활용(CA)과 시퀀스 일관성(SA)을 동시에 최적화합니다.

학습 파이프라인

Pretraining → Post-training 2단계 학습 전략

1. Pretraining

- 커뮤니티 수집 범용 조작 데이터
- 487개 고품질 데이터셋 큐레이션
- SO100/SO101 플랫폼 중심
- 30K 미만 에피소드로 학습
- VLM backbone frozen

2. Post-training

- 태스크별 데이터로 파인 튜닝
- ~50개 에피소드 권장
- 20K 스텝, A100 ~4시간
- 멀티태스크 파인튜닝 지원
- WandB로 학습 모니터링


3. Evaluation

- 동기/비동기 추론 모드
- 시뮬레이션: LIBERO, Meta-World
- 실제 환경: SO100, Koch v1.1
- 성공률 기반 정량 평가
- HF Hub에 모델 배포

성능 벤치마크

LIBERO 벤치마크 성공률 (%)

LIBERO-Spatial LIBERO-Object LIBERO-Goal



Koch v1.1 하드웨어

저비용 오픈소스 로봇 팔 — LeRobot 프레임워크 최적화

하드웨어 구성

- 서보 모터: DYNAMIXEL XL430 + XL330
- 구조: Leader + Follower 듀얼 암
- 제작: 3D 프린팅 부품 + 조립
- 설계: Alexander Koch + HF 개선
- 자유도: 6-DoF + 그리퍼
- 연결: USB (Waveshare 보드)
- 라이선스: 오픈소스 (MIT)

셋업 워크플로우

- **Step 1** 3D 프린팅 (37% infill 권장)
 - **Step 2** 서보 조립 + 배선
 - **Step 3** lerobot-setup-motors (모터 ID 설정)
 - **Step 4** lerobot-calibrate (캘리브레이션)
 - **Step 5** 텔레오퍼레이션 테스트
 - **Step 6** 카메라 설정 (USB 웹캠)
- 캘리브레이션은 SO100/SO101과 동일한 절차

SmolVLA 설치 방법

SmolVLA + Koch v1.1 설치

```
# 1. LeRobot + SmolVLA 설치
git clone https://github.com/huggingface/lerobot.git
cd lerobot
pip install -e ".[smolvla]"

# 2. Koch v1.1 모터 설정 (DYNAMIXEL XL430/XL330)
lerobot-setup-motors \
  --robot.type=koch_follower \
  --robot.port=/dev/ttyUSB0

# 3. 캘리브레이션
lerobot-calibrate \
  --robot.type=koch_follower \
  --robot.port=/dev/ttyUSB0 \
  --robot.id=my_koch_follower

# Python 3.10 권장 | uv 패키지 매니저 추천
```

💡 Koch v1.1은 DYNAMIXEL XL430/XL330 서보 사용 | Leader/Follower 동일 캘리브레이션 프로세스

Koch v1.1 + SmolVLA 실행

① 데이터 수집 (텔레오퍼레이션)

```
# Koch v1.1 텔레오퍼레이션으로 데모 데이터 녹화
lerobot-record \
  --robot.type=koch_follower \
  --teleop.type=koch_leader \
  --dataset.repo_id=${HF_USER}/koch_pick_place \
  --dataset.single_task="Pick up the cube" \
  --episodes=50
```

② 추론 실행 (Inference)

```
# 학습된 SmolVLA 정책으로 Koch v1.1 자율 실행
lerobot-record \
  --robot.type=koch_follower \
  --policy.path=${HF_USER}/smolvla_koch_policy \
  --dataset.repo_id=${HF_USER}/eval_koch \
  --episodes=10
```

SmolVLA 파인튜닝

SmolVLA 파인튜닝 (Koch v1.1 데이터)

```
# Koch v1.1에서 수집한 데이터로 SmolVLA 파인튜닝
lerobot-train \
  --policy.path=lerobot/smolvla_base \
  --dataset.repo_id=${HF_USER}/koch_pick_place \
  --batch_size=64 \
  --steps=20000 \
  --output_dir=outputs/train/koch_smolvla \
  --job_name=koch_smolvla_training \
  --policy.device=cuda \
  --save_freq=2000 \
  --wandb.enable=true

# 권장: ~50 에피소드 | A100 1대 ~4시간 | 체크포인트 자동 저장
```


파인튜닝 팁 & 디버깅

파인튜닝 가이드라인

- **데이터 수량:** 최소 50 에피소드 (25개는 부족)
- **다양성:** 위치 변화당 10+ 에피소드씩 반복
- **Batch size:** 64부터 시작, GPU 허용시 증가
- **Steps:** 20K 기본, 태스크 난이도에 따라 조정
- **모니터링:** WandB 로그로 loss 추이 확인
- **체크포인트:** save_freq=2000 권장
- **환경:** Python 3.10, uv 패키지 매니저 추천

트러블슈팅

- **HTTP 429 오류:** HF Hub 레이트 제한 → 로컬 데이터셋 사용
- **ffmpeg 오류:** DYLD_LIBRARY_PATH 설정 (macOS)
- **성능 저하:** 데이터 품질 점검, 에피소드 리플레이
- **OOM:** batch_size 줄이기, video_backend=pyav
- **캘리브레이션 불일치:** 재캘리브레이션 필수
- **모터 연결:** USB 포트 확인, 점퍼 B 채널
- **최신 버전:** git pull 로 LeRobot 최신화

로보틱스 하드웨어 생태계

플랫폼	서보	구조	가격대	LeRobot	특징
Koch v1.1	DYNAMIXEL	6-DoF Arm	~\$300	✓ 기본	3D 프린팅, 오픈소스
SO100	Feetech STS	6-DoF Arm	~\$110	✓ 기본	최저가, 입문용 최적
SO101	Feetech STS	6-DoF Arm	~\$150	✓ 기본	SO100 개선, 더 견고
ALOHA	DYNAMIXEL	듀얼 7-DoF	~\$20K	✓ 호환	양팔 텔레오퍼레이션
Reachy Mini	DYNAMIXEL	휴머노이드	~\$15K	✓ 호환	상반신 로봇, 교육용



추천

입문자는 SO100/SO101로 시작, 연구 목적이라면 Koch v1.1 (DYNAMIXEL 정밀도), 양팔 조작 연구는 ALOHA를 권장

향후 연구 방향

Cross-Embodiment 일반화

하나의 모델로 다양한 로봇 플랫폼에서 동작. 로봇 형태에 무관한 범용 정책 학습이 핵심 과제입니다.

강화학습 통합

모방학습에 RL을 결합하여 장기 태스크 성능 향상. 자율 탐색을 통한 정책 개선 연구가 활발합니다.

멀티모달 공동 학습

로보틱스 데이터와 웹 스케일 멀티모달 데이터를 함께 학습하여 일반화 능력과 지시 이해력을 강화합니다.

전용 VLM 백본

문서/OCR용 VLM 대신 로봇 환경에 특화된 백본 개발. 공간 추론과 물리 이해에 최적화된 사전학습이 필요합니다.

데이터 스케일링

커뮤니티 데이터 수집 확대와 자동 라벨링 (예: Qwen2.5-VL)으로 데이터 부족 문제를 해결합니다.

효율적 스케일링

모델 크기를 키우되 추론 속도를 유지하는 기법. 양자화, 증류, 어댑터 기반 확장이 연구됩니다.

활용 사례 & 시작하기

VLA 활용 분야

- 물류 창고: 자연어 명령으로 물품 분류/정리
- 제조업: 조립 라인 유연 자동화
- 헬스케어: 의료 물품 배송, 환자 안내
- 가정용: 세탁물 정리, 식기 정돈
- 연구/교육: 저비용 로봇 실험 플랫폼

시작하기 가이드

- Koch v1.1 조립 (3D 프린트 + DYNAMIXEL)
- LeRobot + SmolVLA 설치
- 텔레오퍼레이션으로 50+ 데모 수집
- 파인튜닝 (A100 ~4시간 / RTX 4090도 가능)
- 추론 실행 → 자율 로봇 제어

참고 자료

- SmolVLA 코드: github.com/huggingface/lerobot
- Koch v1.1 조립: huggingface.co/docs/lerobot/koch
- SmolVLA 문서: huggingface.co/docs/lerobot/smolvla
- 모델 체크포인트: huggingface.co/lerobot/smolvla_base
- 논문: arxiv.org/abs/2506.01844 (SmolVLA)